Yo dirigí el análisis; la IA lo ejecutó y la verifiqué en cada paso

Claude Code con un MCP de Postgres de solo lectura, una skill de análisis propia y búsqueda web con Firecrawl.

- **Datos:** Excel → CSV sin limpieza → Postgres en Docker. Las tablas quedan crudas y toda limpieza va en vistas SQL comentadas.
- **Skill `vemo-analyst`:** reglas del caso (no confiar en los datos, cohorte vs calendario, pesos y horizonte, segunda vía obligatoria).
- **Investigación:** un agente con Firecrawl revisó el sitio de Vemo, el reporte de sustentabilidad y benchmarks (Moove, Kovi, churn de conductores, utilización de cargadores).
- **Salida única:** las mismas cifras alimentan el deck, los dashboards, el Google Sheet y el anexo.

Qué delegué y qué decidí yo

La IA ejecutó

- Carga fiel de los 3 Excel y conteos por hoja.
- Queries exploratorias y vistas SQL.
- Script de segunda vía en Python desde los CSV.
- Scaffold de la app (React + Vite) y export a PDF.
- Búsqueda y resumen de fuentes públicas.

Yo decidí

- Usar cohortes cerradas y no el reporte calendario.
- Separar hubs maduros vs nuevos en la promo de Watts.
- Controlar el bono por horas antes de creerle a la correlación.
- Excluir el cierre de Roma y la semana previa a la apertura de Sur B.
- Los supuestos de escala (CPL +50%, volumen ×1.7) y presentar rangos, no puntos.
- Recomendar "ninguna" en Conduce y "no" en Watts.

Verificación: tres capas antes de que una cifra llegue al deck

Celdas Excel vs Postgres
32,740
16 hojas · 0 diferencias

Cifras SQL vs Python
11/11
calculadas por dos vías

Trampas de datos tratadas
8
documentadas en el anexo

- **Capa 1 · carga:** cada celda del Excel se compara contra la base (números exactos, fechas, vacíos vs NULL).
- **Capa 2 · cálculo:** `analysis/vemo_model.py` recalcula desde los CSV crudos y falla si no cuadra con SQL (pestaña "Control de cifras" del Sheet).
- **Capa 3 · sentido de negocio:** cada número se contrasta con el caso (capacidad 700, CAC ≤ $10 k, meta 92%, meta 12% desde el mes 6).

Dónde tuve que corregir a la IA o a la lectura ingenua

#	Lo que salía	Cómo lo detecté	Corrección
1	Watts: SQL y Python difieren en $55/mes	Chequeo cruzado automático	SQL redondeaba el precio a 2 decimales; documentado y con tolerancia explícita
2	Un chequeo de Conduce era tautológico (se comparaba consigo mismo)	Revisé el código del check	Lo reemplacé por el valor de SQL (1,531 firmas)
3	Retención de Hub Roma de 1%	Valor imposible vs el resto (~40%)	Excluí las 43 bajas por cierre de hub
4	"Más bono = más retención" (34% → 43%)	El bono se paga por horas	Controlé por horas: el efecto desaparece
5	"La promo triplicó sesiones"	4 de 6 hubs abrieron en jun–jul	Comparé sólo hubs maduros vs control: ×1.67, temporal
6	D-04 con 14.9% de utilización	Conectores operativos 3/6	Utilización sobre conectores instalados: 7.5%
7	Valores de mayo de un chart escritos de memoria y % ×100 (4610%)	Revisión de cifras y del PDF	Valores tomados de la vista SQL; formato corregido
8	Modelo de Conduce topado en la meta; web de Vemo contradictoria (141/400+/1,000+ puntos)	Sensibilidad y fuentes cruzadas	Presento un rango ($0.9–1.7 M); decido sólo con datos del caso

Límites y siguientes pasos

- **La IA acelera, no decide:** acierta en SQL, pero tiende a tomar correlaciones como causa (bono) y el reporte de Dirección como verdad (calendario).
- **Todo es reproducible:** `setup_postgres.sh` → `03_analytical_views.sql` → `vemo_model.py` regenera los JSON, el Sheet y el deck.
- **Con más tiempo:** curva de CPL por canal, supervivencia (Kaplan-Meier) por hub y distancia, y diff-in-diff de Watts con más hubs control.
- **Lo que pediría a Vemo:** motivo de baja con encuesta, sesiones por segmento en Watts y la capacidad de visitas en Impulso.